INFORME EJECUTIVO

Predicción de abandono de clientes para FinAlpes

Daniel Triviño · Nicolás Bedoya | Taller 2 · MINE-4101 · Uniandes | 9 de noviembre de 2026

En una frase. Un modelo que ordena a los clientes por riesgo de abandono permite dirigir la campaña de retención al ~16 % más riesgoso de la base. En un banco de 20.000 clientes deja ~COP 271 millones al año y recupera su costo en menos de tres meses. Recomendamos implementarlo primero como piloto.

3,2×
mejor que contactar al azar para encontrar a quienes se van (PR-AUC)

13.500
COP de ganancia esperada por cliente evaluado, al año

2,7 meses
para recuperar la inversión de ~COP 61 millones

El problema y los datos

FinAlpes quiere detectar a tiempo a los clientes que van a abandonar el banco para ofrecerles una campaña de retención. La campaña convence al 30 % de quienes iban a irse, pero se paga por cada cliente contactado. Contactar a todos es caro, y contactar al azar desperdicia la mayoría de las ofertas. La pregunta es **a quién contactar y si vale la pena**.

Usamos una muestra de 10.045 clientes europeos de un banco, con 11 variables de perfil comercial. El 20,4 % abandonó. La muestra traía errores: el 11 % de las filas tenía algún dato faltante, y había 45 filas duplicadas, 95 países o géneros mal escritos y 15 filas con valores imposibles (por ejemplo, edades de 130 años). Tras la limpieza quedaron 9.985 clientes. Los faltantes se completan dentro del modelo.

El modelo

Comparamos tres modelos (regresión logística, SVM y XGBoost) con el 80 % de los datos, y reservamos el 20 % restante para una única evaluación final. Los elegimos por su capacidad de *ordenar* a los clientes por riesgo (PR-AUC). La exactitud no sirve aquí: decir que nadie abandona ya acierta el 79,6 %. **XGBoost fue el mejor**: PR-AUC de 0,662 en prueba, 3,2 veces la de contactar al azar. Por decisión ética, el modelo **no usa el género ni el país** del cliente.

Hallazgos

1. **El modelo concentra el abandono.** En la base de prueba, 6 de cada 10 clientes que marca sí iban a irse, frente a 2 de cada 10 al azar. Además, alcanza a más de la mitad de quienes se van. El 10 % más riesgoso concentra el 38 % de los abandonos.

2. **Tres variables explican casi todo.** La edad, el número de productos y la actividad del cliente suman el 90 % del peso de las predicciones. El riesgo sube con la edad hasta los 50–59 años. Con 2 productos es mínimo, y con 3 o 4 se dispara.

3. **La inactividad es la señal más accionable.** Un cliente inactivo de 55 años tiene, en promedio, un riesgo del 68 %, frente al 30 % de uno activo de la misma edad. Es una asociación, no una causa: activar al cliente no garantiza retenerlo.

4. **Hay puntos ciegos.** El modelo casi no detecta el abandono de clientes con 2 productos o menores de 40 años, y subestima el riesgo en Alemania y en mujeres. Para verlos hacen falta

datos de comportamiento (transacciones, reclamos, uso de canales), no otro algoritmo.

Cuánto vale para el banco

Cada acierto vale $r \cdot V - c$, donde r es la tasa de éxito de la oferta, V el ingreso anual del cliente y c el costo de la oferta: se retiene al 30 % y se paga la oferta. Cada falsa alarma cuesta c. Los supuestos para un banco promedio son:

Supuesto	Valor	Fuente
Clientes · abandono anual	20.000 · 15 %	Enunciado (promedio de la banca minorista)
Éxito de la oferta (r)	30 % de los que iban a irse	Enunciado
Ingreso anual por cliente (V)	COP 500.000–900.000 (central: 700.000)	Enunciado (reporte 6-K de Nu, 2026)
Costo por contacto (c)	$V/30$ ∼COP 23.300	Ejercicio de churn del curso (oferta de 50 por cliente de 1.500)
Inversión inicial	∼COP 61 millones	Presupuesto de la Práctica 4 del curso, con el costo-hora de un científico de datos colombiano

- **Ganancia esperada:** ∼COP 13.500 por cliente evaluado y por año, ∼COP 22,6 millones al mes en toda la base. La inversión se recupera en **2,7 meses**, y el ROI a 12 meses es del 344 %.
- **Margen de seguridad:** cada contacto es rentable mientras más del 11 % de los contactados iban a irse. Con la tasa de abandono del banco, el modelo acierta en ∼1 de cada 2.
- **Sensibilidad:** la ganancia es positiva en 11 de las 12 combinaciones de ingreso (COP 500.000–900.000) y costo de la oferta (COP 10.000–100.000). Solo se pierde dinero si la oferta cuesta COP 100.000 y el cliente deja COP 500.000. El supuesto que más pesa es el **costo de la oferta**.
- **Umbral:** contactar al 40 % de la base en lugar del 16 % sube la ganancia ∼18 %, si el banco tiene capacidad para esa campaña.

Recomendación

Implementar el modelo como piloto. Puntuar la base una vez al año y contactar a los clientes con riesgo mayor o igual a 0,33 (∼16 % de la base, unos 3.100 clientes), reservando un grupo de control sin oferta. El piloto mide lo que hoy es un supuesto: el costo real de la oferta y cuántos clientes retiene. Antes de escalar, hay que reentrenar el modelo con clientes del propio banco y sumar datos de comportamiento.

Limitaciones

- **Otro mercado.** El modelo aprendió de clientes europeos en un solo momento. No sabemos si acierta igual con clientes colombianos ni con el paso del tiempo.
- **Supuestos sin validar.** El costo de la oferta y la inversión vienen de ejemplos del curso, sin costos recurrentes. Se usó el ingreso y no el margen, con un solo año de permanencia y el mismo 30 % de éxito para todos.
- **Asociación, no causalidad.** El modelo dice a quién contactar, no por qué se va el cliente ni si la oferta lo hará quedarse.

El detalle está en los notebooks `01_entendimiento` a `07_valor` del repositorio. La declaración de uso de IA generativa (Entregable 7) está en `declaracion_IA.md`.